

Trabalho Prático de Engenharia de Dados

Professor: André Britto de Carvalho

O trabalho prático da disciplina consiste no desenvolvimento de aplicações em bancos de dados relacionais e não relacionais, bem como na implementação de rotinas de integração dos dados num banco de dados no esquema estrela.

Fases do trabalho

O trabalho completo conterá as seguintes fases:

Parte 1 – CRUD Relacional

Parte 2 – CRUD NoSQL

Parte 3 – Integração de dados

Parte 1

A parte 1 consiste no desenvolvimento de um programa que efetua o CRUD (insert, delete, update e leitura) em tabelas no esquema relacional trabalhado em aula. As tabelas são usuário, estudante, vínculo e curso. Essa etapa tem como objetivo o desenvolvimento de um programa que se comunica com um SGBD e executar operações de manipulação de dados.

O grupo está livre para escolher a linguagem de programação/framework. Porém, o SGBD deve ser o postgresql, hospedado na AWS e o banco de dados deve conter todas as tabelas do esquema.

Parte 2

A parte 2 consiste no mapeamento das tabelas dos modelos relacional para o banco de dados MongoDB e em seguida a implementação do CRUD.

Projeto Lógico - NoSQL

O projeto lógico consiste no mapeamento do banco de dados relacional trabalhado na disciplina para a representação do MongoDB. Essa etapa visa a pesquisa e estudo de SGBDs NoSQL e em seguida a representação de cada estrutura no modelo escolhido

Pesquisa e estudo: o grupo deve fazer uma pesquisa por SGBDs NoSQL e suas respectivas representações. A partir dessa pesquisa o grupo deverá escolher o

SGBD que será utilizado. Além disso, o grupo deve buscar métodos de mapeamento de um projeto conceitual ou do projeto lógico no modelo relacional para o NoSQL escolhido.

Mapeamento: Todas as tabelas devem ser representadas no NoSQL. Além disso, o grupo deverá discutir como garantir as restrições definidas (restrição de chave, de integridade referencial, de domínio e not null) e implementar a representação das entidades garantindo essas restrições.

CRUD: CRUD das estruturas referentes às tabelas usuário, estudante, vínculo e curso. Essa etapa tem como objetivo o desenvolvimento de um programa que se comunica com um SGBD NoSQL e executar operações de manipulação de dados.

O grupo está livre para escolher a linguagem de programação/framework. Porém, o SGBD deve ser o MongoDB, hospedado na AWS e o banco de dados deve conter todas as estruturas do esquema relacional mapeadas.

Relatório

Nesta etapa, é necessário enviar o código fonte, idealmente através de um projeto no github ou ferramenta similar. Para cada método, é necessário mostrar o efeito dele no banco de dados. A avaliação da aplicação será através de apresentação para o professor no fim do semestre.

Parte 3 - Integração de dados

A parte 3 do trabalho consiste na construção de em um esquema estrela e construção de pipelines de ETL para preenchimento das tabelas de dimensão e tabela de fatos.

3.1 - Modelagem do esquema estrela

O esquema estrela irá modelar a situação de turmas de graduação, com seus respectivos professores, disciplinas e seus departamentos, semestre de realização e campus.

Os professores são definidos por: nome, tipo da jornada de trabalho, formação e departamento de lotação.

As disciplinas (ou componentes curriculares) são definidas por: código, nome, departamento responsável e número de créditos (cr_total).

Os departamentos (ou unidades) são definidos por: código (ou sigla) e nome.

Os semestres são definidos por: ano e período.

As turmas são associações de professores, com disciplinas, departamento responsável pela disciplina, semestre da turma, e métricas com número discentes matriculados, média de notas (quando disponível), número de aprovados (alunos com nota maior ou igual a 5) (quando disponível) e número de reprovados (alunos com nota menor 5) (quando disponível).

O banco de dados do esquema estrela deve estar disponível num database no servidor RDS de vocês na AWS. Deve ser criado um usuário que será usado pelas rotinas de integração, com as permissões necessárias para o povoamento do banco de dados.

3.2 - Rotinas de ETL

Para preenchimento do modelo estrela, tendo as dimensões quanto a tabela de fatos, será feito através de pipelines na ferramenta Apache Hop.

Serão usadas como fontes o banco de dados relacional utilizado na parte 1 do trabalho prático, considerando todas linhas originais do script, bem como as linhas inseridas através do CRUD.

Além da fonte relacional, também serão usados os arquivos .csv do grupo Ensino do site [dados.ufs.br](https://dados.ufs.br/group/ensino) (<https://dados.ufs.br/group/ensino>). Serão usados os .csv Unidades Acadêmicas, Componentes Curriculares, Docentes e Turmas. Para as turmas devem ser consideradas turmas desde de 2019 até 2025.

Para a avaliação, as tabelas referentes ao esquema estrela estarão vazias e os pipelines devem integrar os dados das diferentes fontes. O grupo pode fazer vários pipelines, não é necessário fazer o pipeline único para preenchimento de todo o esquema estrela. Caso sejam construídos vários pipelines, os grupos podem executar cada um separadamente ou construir um workflow para execução.

Apresentação

Os pipelines construídos deverão ser executados no dia da avaliação. O grupo terá acesso a um computador com o Apache Hop, deverá executar as rotinas de ETL e mostrar o efeito no banco de dados que contém o modelo estrela.